



第二章. 信号的统计检测理论

清华大学电子工程系

杨健

杨健

清华大学电子工程系



上次上课内容回顾：

1 统计信号处理的发展概况

2 几个基本概念和基本方法：

假设检验、先验概率、虚警概率、检测概率、似然函数、似然比

最大后验概率准则、最小错误概率准则


(二者等价)

贝叶斯准则

清楚知道每种检测准则的前提条件



3 记住一张图



4 用统计信号处理的观点去思考问题和解释现象

(如何用最大后验概率准则和贝叶斯准则去分析这次疫情的诊断)



假如代价因子知道，先验概率不知道，该如何处理？

1939年瓦尔德提出了极小极大风险准则





猜测先验概率 $P'(H_0) = x$

$$\frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{x(C_{10} - C_{00})}{(1-x)(C_{01} - C_{11})}$$

$$C = C_{00}P(H_0)(1 - P_F) + C_{10}P(H_0)P_F \\ + C_{01}P(H_1)P_M + C_{11}P(H_1)(1 - P_M)$$

$$v = v(x)$$



猜测先验概率 $P'(H_0) = x$

$$\frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{x(C_{10} - C_{00})}{(1-x)(C_{01} - C_{11})}$$

$$C = C_{00}P(H_0)(1 - P_F) + C_{10}P(H_0)P_F \\ + C_{01}P(H_1)P_M + C_{11}P(H_1)(1 - P_M)$$

$$v = v(x)$$

实际先验概率 $P(H_0) = \xi$

平均代价是关于 ξ, x 的函数

$$C(\xi, x) = \xi C_{00}(1 - P_F(v)) + \xi C_{10}P_F(v) \\ + (1 - \xi)C_{01}P_M(v) + (1 - \xi)C_{11}(1 - P_M(v))$$



猜测先验概率 $P'(H_0) = x$

$$\frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{x(C_{10} - C_{00})}{(1-x)(C_{01} - C_{11})}$$

$$C = C_{00}P(H_0)(1 - P_F) + C_{10}P(H_0)P_F \\ + C_{01}P(H_1)P_M + C_{11}P(H_1)(1 - P_M)$$

$$v = v(x)$$

实际先验概率 $P(H_0) = \xi$

平均代价是关于 ξ, x 的函数


$$C(\xi, x) = \xi C_{00}(1 - P_F(v)) + \xi C_{10}P_F(v) \\ + (1 - \xi)C_{01}P_M(v) + (1 - \xi)C_{11}(1 - P_M(v))$$

当 $x = \xi$ 时, 就是贝叶斯准则的情况

$$C_{min}(\xi) = \xi C_{00}(1 - P_F(v)) + \xi C_{10}P_F(v) \\ + (1 - \xi)C_{01}P_M(v) + (1 - \xi)C_{11}(1 - P_M(v))$$




$$C(\xi, x) = \xi C_{00}(1 - P_F(v)) + \xi C_{10}P_F(v) \\ + (1 - \xi)C_{01}P_M(v) + (1 - \xi)C_{11}(1 - P_M(v))$$



如果选取 $x = \xi$, $C_{min}(\xi)$ 是可能得到的最小平均代价 (贝叶斯准则)



$$C(\xi, x) = \xi C_{00}(1 - P_F(v)) + \xi C_{10}P_F(v) \\ + (1 - \xi)C_{01}P_M(v) + (1 - \xi)C_{11}(1 - P_M(v))$$




如果选取 $x = \xi$, $C_{min}(\xi)$ 是可能得到的最小平均代价（贝叶斯准则）

任意取定一个 $x = \xi_1$, 此时 $C(\xi, \xi_1)$ 为一条直线, 并且在 $C_{min}(\xi)$ 之上, 在 $\xi = \xi_1$ 相切。极大风险在 $\xi = 0, 1$ 取到



$$C(\xi, x) = \xi C_{00}(1 - P_F(v)) + \xi C_{10}P_F(v) \\ + (1 - \xi)C_{01}P_M(v) + (1 - \xi)C_{11}(1 - P_M(v))$$



如果选取 $x = \xi$, $C_{min}(\xi)$ 是可能得到的最小平均代价（贝叶斯准则）

任意取定一个 $x = \xi_1$, 此时 $C(\xi, \xi_1)$ 为一条直线, 并且在 $C_{min}(\xi)$ 之上, 在 $\xi = \xi_1$ 相切。极大风险在 $\xi = 0, 1$ 取到

极小极大准则: 当取到 $x = \xi_0$, 且 ξ_0 满足 $C(\xi, \xi_0)$ 斜率为0时, 可以使极大风险极小化, 即 $\xi_0 = \operatorname{argmin}_x \max_{\xi} C(\xi, x)$



极小极大方程:

$$C(\xi, x^*) \text{关于} \xi \text{的斜率为} 0 \Rightarrow C(0, x^*) = C(1, x^*)$$

$$C_{01}P_M(\nu) + C_{11}(1 - P_M(\nu)) = C_{00}(1 - P_F(\nu)) + C_{10}P_F(\nu)$$



极小极大方程:

$$C(\xi, x^*) \text{关于} \xi \text{的斜率为} 0 \Rightarrow C(0, x^*) = C(1, x^*)$$

$$C_{01} P_M(\nu) + C_{11} (1 - P_M(\nu)) = C_{00} (1 - P_F(\nu)) + C_{10} P_F(\nu)$$

得到 x^* 或 ν 后, 判决规则归结于似然比检验:

$$\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0 = \frac{x^* (C_{10} - C_{00})}{(1 - x^*) (C_{01} - C_{11})}$$

此准则下, 在任意先验概率下的代价均为 $C_{min}(x^*) = \max C_{min}(\xi)$



极小极大方程:

$$C(\xi, x^*) \text{关于} \xi \text{的斜率为} 0 \Rightarrow C(0, x^*) = C(1, x^*)$$

$$C_{01}P_M(\nu) + C_{11}(1 - P_M(\nu)) = C_{00}(1 - P_F(\nu)) + C_{10}P_F(\nu)$$

得到 x^* 或 ν 后, 判决规则归结于似然比检验:

$$\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0 = \frac{x^*(C_{10} - C_{00})}{(1 - x^*)(C_{01} - C_{11})}$$

此准则下, 在任意先验概率下的代价均为 $C_{min}(x^*) = \max C_{min}(\xi)$

特殊情况 $C_{00} = C_{11} = 0, C_{10} = C_{01} = 1$ 下, 极小极大方程简化为:

$$P_F = P_M$$



瓦尔德提出的极小极大风险准则

生活启示：

当我们面临重大问题的抉择时，一定要想清楚万一出现最坏的情况时怎么办？由此所带来的后果是否我们能够承受？

1812年，拿破仑带领57万大军进攻俄国，并最终占领了莫斯科，但最后却败于寒冬，最终回国时仅剩3万人。

1941年6月，德国闪击进攻前苏联，虽然歼灭了苏联红军的大量军队，但由于战线过长加上寒冬，最终导致失败。



4. Neyman-Pearson准则

在许多信号检测问题中,要确定代价因子和先验概率是十分困难的,这时,贝叶斯准则就不能采用,在这种情况下可采用Neyman-Pearson准则。



4. Neyman-Pearson准则

在许多信号检测问题中,要确定代价因子和先验概率是十分困难的,这时,贝叶斯准则就不能采用,在这种情况下可采用Neyman-Pearson准则。

Neyman-Pearson准则的基本思想是保持虚警概率恒定,使检测概率最大(或漏检概率最小)。即



4. Neyman-Pearson准则

在许多信号检测问题中,要确定代价因子和先验概率是十分困难的,这时,贝叶斯准则就不能采用,在这种情况下可采用Neyman-Pearson准则。

Neyman-Pearson准则的基本思想是保持虚警概率恒定,使检测概率最大(或漏检概率最小)。即

$$\begin{cases} \min P_M \text{ 或 } \max P_D \\ s.t. P_F = \alpha \end{cases}$$



核心问题:
$$\begin{cases} \max P_D \\ s.t. P_F = \alpha \end{cases}$$



核心问题:
$$\begin{cases} \max P_D \\ s.t. P_F = \alpha \end{cases}$$

拉格朗日乘子法:

$$\begin{aligned} J &= P_D + \gamma(P_F - \alpha) \\ &= \int_{D_1} p_1(r) dr + \gamma \left(\int_{D_1} p_0(r) dr - \alpha \right) \end{aligned}$$



核心问题:
$$\begin{cases} \max P_D \\ s.t. P_F = \alpha \end{cases}$$

拉格朗日乘子法:

$$\begin{aligned} J &= P_D + \gamma(P_F - \alpha) \\ &= \int_{D_1} p_1(r) dr + \gamma \left(\int_{D_1} p_0(r) dr - \alpha \right) \\ &= \int_{D_1} (p_1(r) + \gamma p_0(r)) dr - \gamma \alpha \end{aligned}$$



核心问题:
$$\begin{cases} \max P_D \\ s.t. P_F = \alpha \end{cases}$$

拉格朗日乘子法:

$$\begin{aligned} J &= P_D + \gamma(P_F - \alpha) \\ &= \int_{D_1} p_1(r) dr + \gamma \left(\int_{D_1} p_0(r) dr - \alpha \right) \\ &= \int_{D_1} (p_1(r) + \gamma p_0(r)) dr - \gamma \alpha \end{aligned}$$

最大化 J :

$p_1(r) + \gamma p_0(r) > 0$, 选择 H_1 成立

$$\Rightarrow \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} - \gamma = \lambda$$


如何确定门限 λ :

$$P_F = \int_{D_1: \lambda(r) > \lambda} p_0(r) dr = \alpha$$



奈曼（内曼）：美国统计学家，1894年生于俄国，于1981年在美国去世。

内曼是**假设检验**的统计理论的创始人之一。他与小皮尔逊合著《统计假设试验理论》，发展了假设检验的数学理论，其要旨是把假设检验问题作为一个最优化问题来处理。他们把所有可能的总体分布族看作一个集合，其中考虑了一个与解消假设相对应的备择假设，引进了检验功效函数的概念，以此作为判断检验程序好坏的标准。这种思想使统计推断理论变得非常明确。 **内曼还提出了置信区间的概念**，建立置信区间估计理论.内曼还对抽样引进某些随机操作，以保证所得结果的客观性和可靠性，在统计理论中有以他的姓氏命名的内曼置信区间法、内曼—皮尔森引理、内曼结构等。





小皮尔逊 (E.S. Pearson), 卡尔.皮尔逊之子




◆ 奈曼和皮尔逊在塞尔



卡尔·皮尔逊

卡尔·皮尔逊 (Karl Pearson, 1857年3月27日 ~ 1936年4月27日) 是英国数学家，生物统计学家，数理统计学的创立者，自由思想者，对生物统计学、气象学、社会达尔文主义理论和优生学做出了重大贡献。他被公认是旧派理学派和描述统计学派的代表人物，并被誉为现代统计科学的创立者。



在1901年，皮尔逊与高尔顿等一起创办了《生物统计》杂志。

卡尔皮尔逊的学术贡献：提出复数相关分析，创立直方图分析法，提出卡方分布




卡尔·皮尔逊

K皮尔逊应该算是早期统计学的创始人之一，在他年轻的时候，受到了高尔顿的影响，对统计学开始感兴趣。当高尔顿离开统计学领域，转而研究其它问题的时候，K皮尔逊接替了他的工作，接管了高尔顿的生物统计实验室，而且后来成了《生物统计》期刊的唯一编辑（共同合伙人高尔顿和威尔登已死亡）。

K皮尔逊最大的成就之一就是创造出了**拟合优度检验**。现在我们依然在用，也就是卡方拟合优度检验。这一检验即使在现在依然能看出它的重要性，它可以让你模拟现实中不同的数学模型，然后利用拟合优度检验来确定哪一个更好。

K皮尔逊还完善了高尔顿提出的**相关系数**，并证明了回归中的复相关系数，可以认为，K皮尔逊是复相关系数的提出人。

可惜的是，K皮尔逊晚年控制欲太强，以至于与另一伟大的统计学家Fisher有了很大的分歧，当年Fisher投稿《生物统计》，结果被K皮尔逊百般刁难，最终导致Fisher不再投稿这一杂志，而改投其它杂志，而且几乎以后所有文章也都不再发表在《生物统计》上。二人之间的分歧一直是统计学的一大遗憾。





• 例

$$\begin{aligned} \mathbf{H}_1: \quad r &= a + n \quad (a > 0) \\ \mathbf{H}_0: \quad r &= n \end{aligned} \quad n \sim \mathcal{N}(0, \sigma^2)$$

给出 $P_F = \alpha$ 下的NP准则的判决规则



• 例

$$\begin{aligned} \mathbf{H}_1: \quad r &= a + n \quad (a > 0) \\ \mathbf{H}_0: \quad r &= n \end{aligned} \quad n \sim \mathcal{N}(0, \sigma^2)$$

给出 $P_F = \alpha$ 下的NP准则的判决规则

$$p_1(r) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(r-a)^2}{2\sigma^2}\right)$$

$$p_0(r) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{r^2}{2\sigma^2}\right)$$



• 例 $\mathbf{H}_1: r = a + n \quad (a > 0)$
 $\mathbf{H}_0: r = n$ $n \sim \mathcal{N}(0, \sigma^2)$

给出 $P_F = \alpha$ 下的NP准则的判决规则

$$p_1(r) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(r-a)^2}{2\sigma^2}\right)$$
$$p_0(r) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{r^2}{2\sigma^2}\right)$$
$$\Rightarrow \lambda(r) = \frac{p_1(r)}{p_0(r)} = \exp\left(\frac{2ra - a^2}{2\sigma^2}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0$$



• 例 $\mathbf{H}_1: r = a + n \quad (a > 0)$
 $\mathbf{H}_0: r = n$ $n \sim \mathcal{N}(0, \sigma^2)$

给出 $P_F = \alpha$ 下的NP准则的判决规则

$$\begin{aligned} p_1(r) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(r-a)^2}{2\sigma^2}\right) \\ p_0(r) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{r^2}{2\sigma^2}\right) \end{aligned} \Rightarrow \lambda(r) = \frac{p_1(r)}{p_0(r)} = \exp\left(\frac{2ra - a^2}{2\sigma^2}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0$$
$$\Rightarrow \frac{2ra - a^2}{2\sigma^2} \underset{H_0}{\overset{H_1}{\gtrless}} \ln \lambda_0$$



• 例 $H_1: r = a + n \quad (a > 0)$
 $H_0: r = n$
 $n \sim \mathcal{N}(0, \sigma^2)$

给出 $P_F = \alpha$ 下的NP准则的判决规则

$$\begin{aligned} p_1(r) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(r-a)^2}{2\sigma^2}\right) \\ p_0(r) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{r^2}{2\sigma^2}\right) \end{aligned} \Rightarrow \lambda(r) = \frac{p_1(r)}{p_0(r)} = \exp\left(\frac{2ra - a^2}{2\sigma^2}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0$$
$$\Rightarrow \frac{2ra - a^2}{2\sigma^2} \underset{H_0}{\overset{H_1}{\gtrless}} \ln \lambda_0 \Rightarrow r \underset{H_0}{\overset{H_1}{\gtrless}} \frac{a}{2} + \frac{\sigma^2}{a} \ln \lambda_0 = V$$



• 例 $H_1: r = a + n \quad (a > 0)$
 $H_0: r = n$
 $n \sim \mathcal{N}(0, \sigma^2)$

给出 $P_F = \alpha$ 下的NP准则的判决规则

$$\begin{aligned} p_1(r) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(r-a)^2}{2\sigma^2}\right) \\ p_0(r) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{r^2}{2\sigma^2}\right) \end{aligned} \Rightarrow \lambda(r) = \frac{p_1(r)}{p_0(r)} = \exp\left(\frac{2ra - a^2}{2\sigma^2}\right) \stackrel{H_1}{\underset{H_0}{\gtrless}} \lambda_0$$
$$\Rightarrow \frac{2ra - a^2}{2\sigma^2} \stackrel{H_1}{\underset{H_0}{\gtrless}} \ln \lambda_0 \Rightarrow r \stackrel{H_1}{\underset{H_0}{\gtrless}} \frac{a}{2} + \frac{\sigma^2}{a} \ln \lambda_0 = V$$

确定门限 V :

$$P_F = \int_V^\infty \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{r^2}{2\sigma^2}\right) dr = Q\left(\frac{V}{\sigma}\right) = \alpha \Rightarrow V = \sigma Q^{-1}(\alpha)$$



NP准则的特点：不知道代价因子，也不知道先验概率。

主要应用于雷达领域。

通常的雷达虚警概率一般设定为 10^{-6}



NP准则的特点：不知道代价因子，也不知道先验概率。

主要应用于雷达领域。

通常的雷达虚警概率一般设定为 10^{-6}



5. 似然比检验的工作特性

前面的几个准则均导出似然比检验： $\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0$



5. 似然比检验的工作特性

前面的几个准则均导出似然比检验： $\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$

若将似然比 $\lambda(r)$ 本身当做一个随机变量（本节中之后简记为 λ ），
则 λ 也有对应的条件概率密度函数：



5. 似然比检验的工作特性

前面的几个准则均导出似然比检验: $\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$

若将似然比 $\lambda(r)$ 本身当做一个随机变量 (本节中之后简记为 λ) ,
则 λ 也有对应的条件概率密度函数:

$$H_0 \text{ 假设为真时, } q_0(\lambda) = \frac{p_0(r)}{|d\lambda/dr|}$$

$$H_1 \text{ 假设为真时, } q_1(\lambda) = \frac{p_1(r)}{|d\lambda/dr|}$$

$$q_i(\lambda)|d\lambda| = p_i(r)|dr|$$



5. 似然比检验的工作特性

前面的几个准则均导出似然比检验: $\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$

若将似然比 $\lambda(r)$ 本身当做一个随机变量 (本节中之后简记为 λ) ,
则 λ 也有对应的条件概率密度函数:

$$H_0 \text{ 假设为真时, } q_0(\lambda) = \frac{p_0(r)}{|d\lambda/dr|}$$

$$H_1 \text{ 假设为真时, } q_1(\lambda) = \frac{p_1(r)}{|d\lambda/dr|}$$

$$q_i(\lambda)|d\lambda| = p_i(r)|dr|$$

$$\Rightarrow \frac{p_1(r)}{p_0(r)} = \frac{q_1(\lambda)}{q_0(\lambda)}$$



因此原本用 r 表示的公式现在可用 λ 来表示：

似然比 $\lambda = \frac{p_1(r)}{p_0(r)} = \frac{q_1(\lambda)}{q_0(\lambda)}$

门限 $\lambda_0 = \frac{q_1(\lambda_0)}{q_0(\lambda_0)}$



因此原本用 r 表示的公式现在可用 λ 来表示：

似然比 $\lambda = \frac{p_1(r)}{p_0(r)} = \frac{q_1(\lambda)}{q_0(\lambda)}$

门限 $\lambda_0 = \frac{q_1(\lambda_0)}{q_0(\lambda_0)}$

两类错误概率

$$P_F = \int_{\lambda_0}^{\infty} q_0(\lambda) d\lambda$$

$$P_M = \int_0^{\lambda_0} q_1(\lambda) d\lambda$$



因此原本用 r 表示的公式现在可用 λ 来表示:


似然比 $\lambda = \frac{p_1(r)}{p_0(r)} = \frac{q_1(\lambda)}{q_0(\lambda)}$

门限 $\lambda_0 = \frac{q_1(\lambda_0)}{q_0(\lambda_0)}$

两类错误概率

$$P_F = \int_{\lambda_0}^{\infty} q_0(\lambda) d\lambda$$

$$P_M = \int_0^{\lambda_0} q_1(\lambda) d\lambda$$





因此原本用 r 表示的公式现在可用 λ 来表示:

似然比 $\lambda = \frac{p_1(r)}{p_0(r)} = \frac{q_1(\lambda)}{q_0(\lambda)}$

门限 $\lambda_0 = \frac{q_1(\lambda_0)}{q_0(\lambda_0)}$

两类错误概率

$$P_F = \int_{\lambda_0}^{\infty} q_0(\lambda) d\lambda$$


$$P_M = \int_0^{\lambda_0} q_1(\lambda) d\lambda$$

如果门限看成是个变量, 则有:

$$dP_F = -q_0(\lambda_0) d\lambda_0$$

$$dP_M = q_1(\lambda_0) d\lambda_0$$

$$dP_D = -dP_M = -q_1(\lambda_0) d\lambda_0$$





因此原本用 r 表示的公式现在可用 λ 来表示:

似然比 $\lambda = \frac{p_1(r)}{p_0(r)} = \frac{q_1(\lambda)}{q_0(\lambda)}$

门限 $\lambda_0 = \frac{q_1(\lambda_0)}{q_0(\lambda_0)}$

两类错误概率

$$P_F = \int_{\lambda_0}^{\infty} q_0(\lambda) d\lambda$$


$$P_M = \int_0^{\lambda_0} q_1(\lambda) d\lambda$$

如果门限看成是个变量, 则有:

$$dP_F = -q_0(\lambda_0) d\lambda_0$$

$$dP_M = q_1(\lambda_0) d\lambda_0$$

$$dP_D = -dP_M = -q_1(\lambda_0) d\lambda_0$$



$$\Rightarrow \lambda_0 = \frac{q_1(\lambda_0)}{q_0(\lambda_0)} = \frac{dP_D}{dP_F}$$




**似然比检验的工作特性，也叫接收机工作特性，简称
ROC(Receiver Operating Characteristic)，为检测概率与虚警
概率的函数关系。**



似然比检验的工作特性，也叫接收机工作特性，简称ROC(Receiver Operating Characteristic)，为检测概率与虚警概率的函数关系。

ROC曲线由 $\{(P_F, P_D) | \lambda_0 \in \mathbb{R}^+\}$ 组成






似然比检验的工作特性，也叫接收机工作特性，简称ROC(Receiver Operating Characteristic)，为检测概率与虚警概率的函数关系。

ROC曲线由 $\{(P_F, P_D) | \lambda_0 \in \mathbb{R}^+\}$ 组成

$(P_F^{(0)}, P_D^{(0)})$ 处的切线斜率就是其对应的门限 $\lambda_0^{(0)}$






似然比检验的工作特性，也叫接收机工作特性，简称ROC(Receiver Operating Characteristic)，为检测概率与虚警概率的函数关系。

ROC曲线由 $\{(P_F, P_D) | \lambda_0 \in \mathbb{R}^+\}$ 组成

$(P_F^{(0)}, P_D^{(0)})$ 处的切线斜率就是其对应的门限 $\lambda_0^{(0)}$

$$P_F = \int_{\lambda_0}^{\infty} q_0(\lambda) d\lambda$$
$$P_D = \int_{\lambda_0}^{\infty} q_1(\lambda) d\lambda$$
$$\lambda_0 = \frac{dP_D}{dP_F}$$





在ROC曲线上可以通过作图求解贝叶斯准则、极小极大准则、NP准则的似然比门限值 λ_0 , 以及相应的 P_F, P_D



在ROC曲线上可以通过作图求解贝叶斯准则、极小极大准则、NP准则的似然比门限值 λ_0 , 以及相应的 P_F, P_D

贝叶斯准则:

$$\lambda_0 = \frac{\xi (C_{10} - C_{00})}{(1 - \xi) (C_{01} - C_{11})}$$



在ROC曲线上可以通过作图求解贝叶斯准则、极小极大准则、NP准则的似然比门限值 λ_0 , 以及相应的 P_F, P_D

贝叶斯准则:

$$\lambda_0 = \frac{\xi (C_{10} - C_{00})}{(1 - \xi) (C_{01} - C_{11})}$$

可求出贝叶斯准则的似然比门限 λ_0 , 并在ROC曲线上找到斜率等于 λ_0 的切线。




在ROC曲线上可以通过作图求解贝叶斯准则、极小极大准则、NP准则的似然比门限值 λ_0 , 以及相应的 P_F, P_D

贝叶斯准则:

$$\lambda_0 = \frac{\xi(C_{10} - C_{00})}{(1 - \xi)(C_{01} - C_{11})}$$

可求出贝叶斯准则的似然比门限 λ_0 , 并在ROC曲线上找到斜率等于 λ_0 的切线。






在ROC曲线上可以通过作图求解贝叶斯准则、极小极大准则、NP准则的似然比门限值 λ_0 , 以及相应的 P_F, P_D

贝叶斯准则:

$$\lambda_0 = \frac{\xi(C_{10} - C_{00})}{(1 - \xi)(C_{01} - C_{11})}$$

可求出贝叶斯准则的似然比门限 λ_0 , 并在ROC曲线上找到斜率等于 λ_0 的切线。

$$\lambda_0 = \frac{dP_D}{dP_F}$$





极小极大准则：

极小极大解应满足“极小极大方程”



极小极大准则：

极小极大解应满足 “极小极大方程”

$$\begin{aligned} C_{01}(1 - P_D) + C_{11}P_D \\ = C_{00}(1 - P_F) + C_{10}P_F \end{aligned}$$



极小极大准则：

极小极大解应满足“极小极大方程”

$$\begin{aligned} C_{01}(1 - P_D) + C_{11}P_D \\ = C_{00}(1 - P_F) + C_{10}P_F \end{aligned}$$

**即为图中“等风险线”。其与
ROC曲线的交点即为极小极大
解。**




极小极大准则：

极小极大解应满足“极小极大方程”

$$\begin{aligned} C_{01}(1 - P_D) + C_{11}P_D \\ = C_{00}(1 - P_F) + C_{10}P_F \end{aligned}$$

即为图中“等风险线”。其与ROC曲线的交点即为极小极大解。






NP准则:

**虚警概率 $P_F = \alpha$ 代表的直线
与ROC曲线的交点为NP准则
的解**



NP准则:

虚警概率 $P_F = \alpha$ 代表的直线
与ROC曲线的交点为NP准则
的解





思考：

如何才能提高检测性能？





6. 多次测量下的简单假设检验

- 假设检验理论由一次测量推广到多次测量
- 令 n 次测量的值为 r_1, r_2, \dots, r_n



多次测量下的简单假设检验

- 假设检验理论由一次测量推广到多次测量
- 令n次测量的值为 r_1, r_2, \dots, r_n

$$p_0(\mathbf{r}) = p_0(r_1, r_2, \dots, r_n)$$

$$p_1(\mathbf{r}) = p_1(r_1, r_2, \dots, r_n)$$



多次测量下的简单假设检验

- 假设检验理论由一次测量推广到多次测量
- 令n次测量的值为 r_1, r_2, \dots, r_n

$$p_0(\mathbf{r}) = p_0(r_1, r_2, \dots, r_n)$$

$$p_1(\mathbf{r}) = p_1(r_1, r_2, \dots, r_n)$$

- 多次测量下的简单假设检验，似然比检验的判决规则为

$$\lambda(\mathbf{r}) = \frac{p_1(\mathbf{r})}{p_0(\mathbf{r})} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0$$



直观表示

- N次测量结果 \longrightarrow N维笛卡尔空间的一点
- 判决策略 \longrightarrow 空间划分策略
- 判决面 \longrightarrow 空间超曲面




直观表示

- N次测量结果 \longrightarrow N维笛卡尔空间的一点
- 判决策略 \longrightarrow 空间划分策略
- 判决面 \longrightarrow 空间超曲面
- 判决面方程 $\lambda(\mathbf{r}) = \lambda_0$
- 观测矢量落在 R_0 区域时 $\lambda(\mathbf{r}) < \lambda_0$
- 观测矢量落在 R_1 区域时 $\lambda(\mathbf{r}) > \lambda_0$



直观表示

- N次测量结果 \longrightarrow N维笛卡尔空间的一点
- 判决策略 \longrightarrow 空间划分策略
- 判决面 \longrightarrow 空间超曲面
- 判决面方程 $\lambda(\mathbf{r}) = \lambda_0$
- 观测矢量落在 R_0 区域时 $\lambda(\mathbf{r}) < \lambda_0$
- 观测矢量落在 R_1 区域时 $\lambda(\mathbf{r}) > \lambda_0$






数学上：把一元函数推广到多元函数
统计上：一元统计推广到多元统计

直观表示

- N次测量结果 \longrightarrow N维笛卡尔空间的一点
- 判决策略 \longrightarrow 空间划分策略
- 判决面 \longrightarrow 空间超曲面
- 判决面方程 $\lambda(\mathbf{r}) = \lambda_0$
- 观测矢量落在 R_0 区域时 $\lambda(\mathbf{r}) < \lambda_0$
- 观测矢量落在 R_1 区域时 $\lambda(\mathbf{r}) > \lambda_0$





6.1 多次测量下的贝叶斯准则

- 已知判决的代价矩阵

$$C = \begin{bmatrix} C_{00} & C_{01} \\ C_{10} & C_{11} \end{bmatrix}$$

- 已知假设 H_0 的先验概率 ξ , 假设 H_1 的先验概率 $1 - \xi$)



多次测量下的贝叶斯准则

- 已知判决的代价矩阵

$$C = \begin{bmatrix} C_{00} & C_{01} \\ C_{10} & C_{11} \end{bmatrix}$$

- 已知假设 H_0 的先验概率 ξ , 假设 H_1 的先验概率 $(1 - \xi)$
- 类似单次测量贝叶斯准则, 可推导出每一判决的平均风险是

$$\overline{C} = \xi C_{10} + (1 - \xi) C_{11} + \int_{R_0} [(1 - \xi)(C_{01} - C_{11})p_1(\mathbf{r}) - \xi(C_{10} - C_{00})p_0(\mathbf{r})] d\mathbf{r}$$



- 选择区域 R_0 , 使上式积分中被积函数为负值, 就可以使平均代价最小, 则判定 H_0 为真的条件是

$$\xi(C_{10} - C_{00})p_0(\mathbf{r}) > (1 - \xi)(C_{01} - C_{11})p_1(\mathbf{r})$$



- 选择区域 R_0 , 使上式积分中被积函数为负值, 就可以使平均代价最小, 则判定 H_0 为真的条件是

$$\xi(C_{10} - C_{00})p_0(\mathbf{r}) > (1 - \xi)(C_{01} - C_{11})p_1(\mathbf{r})$$

$$\frac{p_1(\mathbf{r})}{p_0(\mathbf{r})} < \frac{\xi(C_{10} - C_{00})}{(1 - \xi)(C_{01} - C_{11})} = \lambda_0$$

- 判决面方程由 $\lambda(\mathbf{r}) = \lambda_0$ 决定



- 例
- 若接收信号的 m 次独立观测为 r_1, r_2, \dots, r_m
- 每个噪声样本 $n_i, i = 1, 2, \dots, m$ 都是独立同分布的 $(0, \sigma_n^2)$ 高斯变量，噪声样本与信号样本统计独立
- 多样本的二元假设检验

$$\begin{cases} H_1: r_i = A + n_i, & i = 1, 2, \dots, m \\ H_0: r_i = n_i & i = 1, 2, \dots, m \end{cases}$$

- 给出似然比检验最佳检测器的形式



- 在假设 H_1 下, r_i 是 $N(A, \sigma_n^2)$ 变量
- 在假设 H_0 下, r_i 是 $N(0, \sigma_n^2)$ 变量
- **两种假设下 r_i 的概率密度分布函数为**

$$p_1(r_i) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{(r_i - A)^2}{2\sigma_n^2} \right\} \quad p_0(r_i) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r_i^2}{2\sigma_n^2} \right\}$$



- 在假设 H_1 下, r_i 是 $N(A, \sigma_n^2)$ 变量
- 在假设 H_0 下, r_i 是 $N(0, \sigma_n^2)$ 变量
- **两种假设下 r_i 的概率密度分布函数为**

$$p_1(r_i) = \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{(r_i - A)^2}{2\sigma_n^2}\right\} \quad p_0(r_i) = \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{r_i^2}{2\sigma_n^2}\right\}$$

- **由于噪声是统计独立的, 所以各个 r_i 也是统计独立的**
- **样本矢量的概率密度分布函数为**

$$p_1(\mathbf{r}) = \prod_{i=1}^m p_1(r_i) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{\frac{m}{2}} \exp\left\{-\sum_{i=1}^m \frac{(r_i - A)^2}{2\sigma_n^2}\right\}$$
$$p_0(\mathbf{r}) = \prod_{i=1}^m p_0(r_i) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{\frac{m}{2}} \exp\left\{-\sum_{i=1}^m \frac{r_i^2}{2\sigma_n^2}\right\}$$



- 似然比为

$$\lambda(\mathbf{r}) = \frac{p_1(\mathbf{r})}{p_0(\mathbf{r})} = \exp \left\{ - \sum_{i=1}^m \frac{A^2 - 2Ar_i}{2\sigma_n^2} \right\}$$



- 似然比为

$$\lambda(\mathbf{r}) = \frac{p_1(\mathbf{r})}{p_0(\mathbf{r})} = \exp \left\{ - \sum_{i=1}^m \frac{A^2 - 2Ar_i}{2\sigma_n^2} \right\}$$

- 对数似然比为

$$\ln \lambda(\mathbf{r}) = \frac{A}{\sigma_n^2} \sum_{i=1}^m r_i - \frac{mA^2}{2\sigma_n^2}$$



- 似然比为

$$\lambda(\mathbf{r}) = \frac{p_1(\mathbf{r})}{p_0(\mathbf{r})} = \exp \left\{ - \sum_{i=1}^m \frac{A^2 - 2Ar_i}{2\sigma_n^2} \right\}$$

- 对数似然比为

$$\ln \lambda(\mathbf{r}) = \frac{A}{\sigma_n^2} \sum_{i=1}^m r_i - \frac{mA^2}{2\sigma_n^2}$$

- 似然比检验为

$$\frac{A}{\sigma_n^2} \sum_{i=1}^m r_i - \frac{mA^2}{2\sigma_n^2} \underset{H_0}{\overset{H_1}{\geq}} \ln \lambda_0$$



- 似然比为

$$\lambda(\mathbf{r}) = \frac{p_1(\mathbf{r})}{p_0(\mathbf{r})} = \exp \left\{ - \sum_{i=1}^m \frac{A^2 - 2Ar_i}{2\sigma_n^2} \right\}$$

- 对数似然比为

$$\ln \lambda(\mathbf{r}) = \frac{A}{\sigma_n^2} \sum_{i=1}^m r_i - \frac{mA^2}{2\sigma_n^2}$$

- 似然比检验为

$$\frac{A}{\sigma_n^2} \sum_{i=1}^m r_i - \frac{mA^2}{2\sigma_n^2} \underset{H_0}{\overset{H_1}{\geq}} \ln \lambda_0$$

- 等效为

$$\frac{1}{m} \sum_{i=1}^m r_i \underset{H_0}{\overset{H_1}{\geq}} \frac{A}{2} + \frac{\sigma_n^2}{mA} \ln \lambda_0 = V_T$$



检验统计量的似然函数： $\hat{r} = \frac{1}{m} \sum_{i=1}^m r_i$



检验统计量的似然函数: $\hat{r} = \frac{1}{m} \sum_{i=1}^m r_i$

$$E(\hat{r}) = E\left(\frac{1}{m} \sum_{i=1}^m r_i\right) = \begin{cases} 0, & H_0 \\ A, & H_1 \end{cases}$$



检验统计量的似然函数: $\hat{r} = \frac{1}{m} \sum_{i=1}^m r_i$

$$E(\hat{r}) = E\left(\frac{1}{m} \sum_{i=1}^m r_i\right) = \begin{cases} 0, & H_0 \\ A, & H_1 \end{cases}$$

$$Var(\hat{r}) = E((\hat{r} - E(\hat{r}))^2) = E\left(\left(\frac{1}{m} \sum_{i=1}^m n_i\right)^2\right) = \frac{\sigma^2}{m}$$



检验统计量的似然函数: $\hat{r} = \frac{1}{m} \sum_{i=1}^m r_i$

$$E(\hat{r}) = E\left(\frac{1}{m} \sum_{i=1}^m r_i\right) = \begin{cases} 0, & H_0 \\ A, & H_1 \end{cases}$$

$$Var(\hat{r}) = E((\hat{r} - E(\hat{r}))^2) = E\left(\left(\frac{1}{m} \sum_{i=1}^m n_i\right)^2\right) = \frac{\sigma^2}{m}$$

$$p_0(\hat{r}) = \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m\hat{r}^2}{2\sigma^2}\right)$$

$$p_1(\hat{r}) = \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m(\hat{r} - A)^2}{2\sigma^2}\right)$$



检验统计量的似然函数： $\hat{r} = \frac{1}{m} \sum_{i=1}^m r_i$

$$E(\hat{r}) = E\left(\frac{1}{m} \sum_{i=1}^m r_i\right) = \begin{cases} 0, & H_0 \\ A, & H_1 \end{cases}$$

$$Var(\hat{r}) = E((\hat{r} - E(\hat{r}))^2) = E\left(\left(\frac{1}{m} \sum_{i=1}^m n_i\right)^2\right) = \frac{\sigma^2}{m}$$

$$p_0(\hat{r}) = \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m\hat{r}^2}{2\sigma^2}\right)$$

$$p_1(\hat{r}) = \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m(\hat{r} - A)^2}{2\sigma^2}\right)$$

相比单次观测，方差减小



检验统计量的似然函数: $\hat{r} = \frac{1}{m} \sum_{i=1}^m r_i$


$$E(\hat{r}) = E\left(\frac{1}{m} \sum_{i=1}^m r_i\right) = \begin{cases} 0, & H_0 \\ A, & H_1 \end{cases}$$

$$\text{Var}(\hat{r}) = E((\hat{r} - E(\hat{r}))^2) = E\left(\left(\frac{1}{m} \sum_{i=1}^m n_i\right)^2\right) = \frac{\sigma^2}{m}$$

$$p_0(\hat{r}) = \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m\hat{r}^2}{2\sigma^2}\right)$$

$$p_1(\hat{r}) = \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m(\hat{r} - A)^2}{2\sigma^2}\right)$$

相比单次观测，方差减小





错误概率

$$P_F = \int_{V_T}^{\infty} p_0(\hat{r}) d\hat{r} = \int_{V_T}^{\infty} \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m\hat{r}^2}{2\sigma^2}\right) d\hat{r} = Q\left(\frac{V_T}{\sqrt{\sigma^2/m}}\right)$$

$$P_M = \int_{V_T}^{\infty} p_0(\hat{r}) d\hat{r} = \int_{-\infty}^{V_T} \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m(\hat{r} - A)^2}{2\sigma^2}\right) d\hat{r} = Q\left(\frac{A - V_T}{\sqrt{\sigma^2/m}}\right)$$




错误概率

$$P_F = \int_{V_T}^{\infty} p_0(\hat{r}) d\hat{r} = \int_{V_T}^{\infty} \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m\hat{r}^2}{2\sigma^2}\right) d\hat{r} = Q\left(\frac{V_T}{\sqrt{\sigma^2/m}}\right)$$

$$P_M = \int_{V_T}^{\infty} p_0(\hat{r}) d\hat{r} = \int_{-\infty}^{V_T} \frac{\sqrt{m}}{\sqrt{2\pi}\sigma} \exp\left(-\frac{m(\hat{r}-A)^2}{2\sigma^2}\right) d\hat{r} = Q\left(\frac{A-V_T}{\sqrt{\sigma^2/m}}\right)$$

虚警概率随观测样本数的曲线 ($A=1, V_T=0.5, \sigma^2=1$)





思考与讨论

学会用统计信号处理的思维去思考

以COVID-19为例：

*中日友好医院：三次核酸检测仍呈阴性

如何从统计信号处理的观点看待这些问题？



复习:

1 理解和掌握几个基本概念与检测方法

奈曼-皮尔逊准则

贝叶斯准则

似然比工作特性、 ROC曲线

多次测量下的检测及优点

清楚知道每种检测准则的前提条件

2 逐步学会如何用统计信号处理的思维去分析问题和解决问题



作业：

1. 设有下列两种假设：

$$H_0 : x = n$$

$$H_1 : x = a + n$$

其中 $a > 0$ 为常数， $n \sim N(0, \sigma^2)$ 。如果要求 $P_F = \alpha$ ，试设计相应的最佳接收机，

确定其检测概率 P_D ，并画出 $P_D \sim SNR = a/\sigma$ 或 $(a/\sigma)^2$ 的关系曲线。

2. 针对上述两个假设，假定 $C_{00} = C_{11} = 1, C_{10} = 10, C_{01} = 100$ ， $n \sim N(0, 1)$ 。

试求：

1) 设计相应的最佳接收机；

2) $a=3$ 时的 ξ_0 值，并画出 $\bar{C}_{\min}(\xi)$ 的曲线；(此处是指求先验概率的估计值)



谢谢大家!

