



# 第二章. 信号的统计检测理论

清华大学电子工程系

杨健

杨健

清华大学电子工程系



# 平均的魅力

**罪犯平均的面孔画像更符合真实情况 （高尔顿）**

**平均的面孔更具有吸引力 （美、日、德实验验证）**

**平均翼长的鸟在暴风雨中更能生存**

**平均身高或许最好！ （人类学家西蒙）**


**平均的偏差**

**平均收入**

**平均的河流深度**



# 神童---弗朗西斯·高尔顿



弗朗西斯·高尔顿 (Francis Galton, 1822年2月16日 - 1911年1月17日), 英国科学家和探险家。学术研究兴趣广泛, 包括人类学、地理、数学、力学、气象学、心理学、统计学等方面。他着重研究个别差异, 从遗传的角度研究个别差异形成的原因, 开创了优生学。他关于人类官能的研究开辟了个体心理和心理测验研究的新途径。他系统深入的研究了指纹学, 明确指出指纹终身不变; 指纹可以识别; 指纹可以分类。

**他是相关系数的提出者, 是生物统计学的先驱。**

他是第一个明确提出普通能力和特殊能力主张的人。他在调查了1768 - 1868 年这 100 年间英国的首相、将军、文学家和科学家共 977 名获得智力成熟的人的家谱后发现, 其中有 89 个父亲、129 个儿子、114 个兄弟, 共 332 名杰出人士。而在一般老百姓中每 4000 人才产生一名杰出人士。因此他认为普通能力是遗传的。在调查 30 家有艺术能力的家庭中, 他发现这些家庭中的子女也有艺术能力的占 64%; 而 150 家无艺术能力的家庭, 其子女中只有 21% 有艺术能力

高尔顿的学术继承人、卡尔·皮尔逊在提到高尔顿的博学时有个有趣的说法: “高尔顿比 10 个生物学家中的 9 个更懂数学和物理, 比 20 个数学家中的 19 个更懂生物, 而比 50 个生物学家中的 49 个更懂疾病和畸形儿的知识。



- 例

- 若接收信号的 $m$ 次独立观测为  $r_1, r_2, \dots, r_m$

- 每个噪声样本  $n_i, i = 1, 2, \dots, m$  都是独立同分布的拉普拉斯噪声，噪声样本与信号样本统计独立

$$p(n_i) = \frac{1}{\sqrt{2} \sigma_n} \exp \left\{ -\frac{\sqrt{2} |n_i|}{\sigma_n} \right\}$$



## • 例

- 若接收信号的 $m$ 次独立观测为  $r_1, r_2, \dots, r_m$

- 每个噪声样本  $n_i, i = 1, 2, \dots, m$  都是独立同分布的拉普拉斯噪声，噪声样本与信号样本统计独立

$$p(n_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|n_i|}{\sigma_n}\right\}$$

- 多样本的二元假设检验

$$\begin{cases} H_1: r_i = A + n_i, & i = 1, 2, \dots, m \\ H_0: r_i = n_i & i = 1, 2, \dots, m \end{cases}$$

- 其中 $A$ 为正

- 给出似然比检验最佳检测器的形式



- 两种假设下  $r_i$  的概率密度分布函数为

$$p_1(r_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|r_i - A|}{\sigma_n}\right\} \quad p_0(r_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|r_i|}{\sigma_n}\right\}$$



- 两种假设下  $r_i$  的概率密度分布函数为

$$p_1(r_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|r_i - A|}{\sigma_n}\right\} \quad p_0(r_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|r_i|}{\sigma_n}\right\}$$

- 由于噪声是统计独立的，所以各个  $r_i$  也是统计独立的
- 样本矢量的概率密度分布函数为

$$p_1(\mathbf{r}) = \prod_{i=1}^m p_1(r_i) = \left(\frac{1}{2\sigma_n^2}\right)^{\frac{m}{2}} \exp\left\{-\frac{\sqrt{2}}{\sigma_n} \sum_{i=1}^m |r_i - A|\right\}$$
$$p_0(\mathbf{r}) = \prod_{i=1}^m p_0(r_i) = \left(\frac{1}{2\sigma_n^2}\right)^{\frac{m}{2}} \exp\left\{-\frac{\sqrt{2}}{\sigma_n} \sum_{i=1}^m |r_i|\right\}$$



- 两种假设下  $r_i$  的概率密度分布函数为

$$p_1(r_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|r_i - A|}{\sigma_n}\right\} \quad p_0(r_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|r_i|}{\sigma_n}\right\}$$

- 由于噪声是统计独立的，所以各个  $r_i$  也是统计独立的
- 样本矢量的概率密度分布函数为

$$p_1(\mathbf{r}) = \prod_{i=1}^m p_1(r_i) = \left(\frac{1}{2\sigma_n^2}\right)^{\frac{m}{2}} \exp\left\{-\frac{\sqrt{2}}{\sigma_n} \sum_{i=1}^m |r_i - A|\right\}$$
$$p_0(\mathbf{r}) = \prod_{i=1}^m p_0(r_i) = \left(\frac{1}{2\sigma_n^2}\right)^{\frac{m}{2}} \exp\left\{-\frac{\sqrt{2}}{\sigma_n} \sum_{i=1}^m |r_i|\right\}$$

- 对数似然比为

$$\ln \lambda(\mathbf{r}) = \frac{\sqrt{2}}{\sigma_n} \sum_{i=1}^m |r_i| - |r_i - A|$$





- 设样本总数为  $N$
- $r_i < 0$  的样本数为  $N_1$
- $0 < r_i < A$  的样本数为  $N_2$
- $r_i > A$  的样本数为  $N_3$



- 设样本总数为  $N$
- $r_i < 0$  的样本数为  $N_1$
- $0 < r_i < A$  的样本数为  $N_2$
- $r_i > A$  的样本数为  $N_3$
- 则判决规则为

$$[(N_3 - (N_1 + N_2))] \frac{A}{2} + \sum_{0 < r_i < A} r_i \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma_n}{2\sqrt{2}} \ln \lambda_0$$

$$N_3 A + \sum_{0 < r_i < A} r_i \underset{H_0}{\overset{H_1}{\geq}} \frac{NA}{2} + \frac{\sigma_n}{2\sqrt{2}} \ln \lambda_0$$

- 判决过程为：对超过  $A$  的样本值计数，对在  $0$  和  $A$  之间的样本值求和，在通过特定门限比较做出判决



## • 作业

- 若接收信号的 $m$ 次独立观测为  $r_1, r_2, \dots, r_m$

- 每个噪声样本  $n_i, i = 1, 2, \dots, m$  都是独立同分布的拉普拉斯噪声，噪声样本与信号样本统计独立

$$p(n_i) = \frac{1}{\sqrt{2}\sigma_n} \exp\left\{-\frac{\sqrt{2}|n_i|}{\sigma_n}\right\}$$

- 多样本的二元假设检验

$$\begin{cases} H_1: r_i = A + n_i, & i = 1, 2, \dots, m \\ H_0: r_i = n_i & i = 1, 2, \dots, m \end{cases}$$

- 其中 $A = -10$

- 给出似然比检验最佳检测器的形式



## 多次测量极小极大准则

- 已知判决的代价矩阵

$$C = \begin{bmatrix} C_{00} & C_{01} \\ C_{10} & C_{11} \end{bmatrix}$$

- 假设  $H_0$  和  $H_1$  的先验概率未知，记猜测的先验概率为  $x$



## 多次测量极小极大准则

- 已知判决的代价矩阵

$$C = \begin{bmatrix} C_{00} & C_{01} \\ C_{10} & C_{11} \end{bmatrix}$$

- 假设  $H_0$  和  $H_1$  的先验概率未知，记猜测的先验概率为  $x$
- 对于先验概率  $\xi$  的每一个值，均可以利用贝叶斯准则计算出对应的最小平均风险  $\bar{C}_{\min}(\xi)$ ，即最小平均风险是先验概率的函数



## 多次测量极小极大准则

- 已知判决的代价矩阵

$$C = \begin{bmatrix} C_{00} & C_{01} \\ C_{10} & C_{11} \end{bmatrix}$$

- 假设  $H_0$  和  $H_1$  的先验概率未知，记猜测的先验概率为  $x$
- 对于先验概率  $\xi$  的每一个值，均可以利用贝叶斯准则计算出对应的最小平均风险  $\bar{C}_{\min}(\xi)$ ，即最小平均风险是先验概率的函数
- 采用使  $\bar{C}_{\min}(\xi)$  达到极大的先验概率  $\xi_0$  作为假定的先验概率，再采用贝叶斯准则



# 多次测量极小极大准则

- 已知判决的代价矩阵

$$C = \begin{bmatrix} C_{00} & C_{01} \\ C_{10} & C_{11} \end{bmatrix}$$

- 假设  $H_0$  和  $H_1$  的先验概率未知，记猜测的先验概率为  $x$
- 对于先验概率  $\xi$  的每一个值，均可以利用贝叶斯准则计算出对应的最小平均风险  $\bar{C}_{\min}(\xi)$ ，即最小平均风险是先验概率的函数
- 采用使  $\bar{C}_{\min}(\xi)$  达到极大的先验概率  $\xi_0$  作为假定的先验概率，再采用贝叶斯准则

$$C(\xi, x) = \xi C_{00} (1 - P_F(v)) + \xi C_{10} P_F(v) \\ + (1 - \xi) C_{01} P_M(v) + (1 - \xi) C_{11} (1 - P_M(v))$$



极小极大方程:

$$C(\xi, x^*) \text{关于 } \xi \text{ 的斜率为0} \Rightarrow C(0, x^*) = C(1, x^*)$$

$$C_{01}P_M(\nu) + C_{11}(1 - P_M(\nu)) = C_{00}(1 - P_F(\nu)) + C_{10}P_F(\nu)$$

得到  $x^*$  或  $\nu$  后, 判决规则归结于似然比检验:

$$\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0 = \frac{x^*(C_{10} - C_{00})}{(1 - x^*)(C_{01} - C_{11})}$$

此准则下, 在任意先验概率下的代价均为  $C_{min}(x^*) = \max_{\xi} C_{min}(\xi)$





## 多次测量奈曼-皮尔逊准则

- 判决的代价矩阵未知
- 假设  $H_0$  和  $H_1$  的先验概率未知
- 解决优化问题，其中优化变量为  $D_1$

$$\begin{aligned} \max \quad & P_D = \int_{D_1} p_1(\mathbf{r}) d\mathbf{r} \\ \text{s.t.} \quad & P_f = \int_{D_1} p_0(\mathbf{r}) d\mathbf{r} \leq \alpha \end{aligned}$$



# 多次测量奈曼-皮尔逊准则

- 判决的代价矩阵未知
- 假设  $H_0$  和  $H_1$  的先验概率未知
- 解决优化问题，其中优化变量为  $D_1$

$$\max P_D = \int_{D_1} p_1(\mathbf{r}) d\mathbf{r}$$

$$s.t. P_f = \int_{D_1} p_0(\mathbf{r}) d\mathbf{r} \leq \alpha$$

变分法

- 利用Lagrange乘数法可以得到判决  $D_1$  的条件，在特殊情况下

$$\frac{p_1(\mathbf{r})}{p_0(\mathbf{r})} > \mu$$

$$P_F = \int_{\mu}^{\infty} p_0(\lambda) d\lambda = \alpha$$



## 7 多元简单假设检验

- 一元函数 $\rightarrow$ 多元函数 （一次测量 $\rightarrow$ 多次测量） **二元假设**



## 7 多元简单假设检验

- 一元函数 $\rightarrow$ 多元函数 （一次测量 $\rightarrow$ 多次测量） **二元假设**
- **二元假设 $\rightarrow$ 多元假设**



## 7 多元简单假设检验

- 一元函数 $\rightarrow$ 多元函数 （一次测量 $\rightarrow$ 多次测量） **二元假设**
- **二元假设 $\rightarrow$ 多元假设**
- $m$ 元数字通信系统中，要用 $m$ 个信号来分别代表 $m$ 个符号，即存在 $m$ 个假设，要从中选择1个，这就是 $m$ 元假设检验问题
- 仅考虑简单假设检验的情况，在多元假设检验中通常只考虑贝叶斯准则，认为各类假设的先验概率和判决的代价因子是已知的。



- 按照贝叶斯检验的基本思想,做出一个判决是要付出代价的,为了反映不同类型代价的大小,对每种可能的判决结果定义一个代价因子:
- $C_{ij}$  :  $H_j$  为真时,判  $H_i$  成立应付出的代价.



- 按照贝叶斯检验的基本思想,做出一个判决是要付出代价的,为了反映不同类型代价的大小,对每种可能的判决结果定义一个代价因子:
- $C_{ij}$  :  $H_j$  为真时,判  $H_i$  成立应付出的代价.
- 给定N维观测样本矢量  $\mathbf{r}$  之后,同选择假设  $H_j$  有关的代价为

$$C_j = \sum_{i=1}^m C_{ji} p(H_i | \mathbf{r})$$

后验概率



- 贝叶斯准则的判决规则是选择与最小的  $C_j$  对应的假设  $H_j$
- 如果采用的代价因子为  $C_{ij} = 1 (i \neq j), C_{ii} = 0$

即正确判决不付出代价，各种错误判决付出同等代价





- 贝叶斯准则的判决规则是选择与最小的  $C_j$  对应的假设  $H_j$
- 如果采用的代价因子为  $C_{ij} = 1 (i \neq j), C_{ii} = 0$

即正确判决不付出代价，各种错误判决付出同等代价

由  $C_j = \sum_{i=1}^m C_{ji} p(H_i | \mathbf{r})$  可知该情况下最小的  $C_j$  对应于最大的

$$p(H_j | \mathbf{r})$$

$$p(H_j | \mathbf{r}) = \frac{p(H_j) p_j(\mathbf{r} | H_j)}{p(\mathbf{r})}$$

- 在各种假设先验概率相等的场合，后验概率最大相当于似然函数最大。



- 例：在加性高斯噪声中检测四个常值信号之一的问题
- 相应的四元假设检验是

$$\begin{cases} H_1: r_i = 1 + n_i, & i = 1, 2, \dots, N \\ H_2: r_i = 2 + n_i, & i = 1, 2, \dots, N \\ H_3: r_i = 3 + n_i, & i = 1, 2, \dots, N \\ H_4: r_i = 4 + n_i, & i = 1, 2, \dots, N \end{cases}$$

- 每个噪声样本  $n_i, i = 1, 2, \dots, m$  都是独立同分布的  $N(0, \sigma^2)$  高斯变量，噪声样本与信号样本统计独立
- 代价因子  $C_{ij} = 1 (i \neq j), C_{ii} = 0$ ，所有假设等先验概率



- 这种情况下，贝叶斯准则转化为最大似然准则，各假设下的似然函数为

$$p_k(\mathbf{r}) = \left( \frac{1}{2\pi\sigma_n^2} \right)^{\frac{N}{2}} \exp \left\{ - \sum_{i=1}^N \frac{(r_i - k)^2}{2\sigma_n^2} \right\} \quad k = 1, 2, 3, 4$$



- 这种情况下，贝叶斯准则转化为最大似然准则，各假设下的似然函数为

$$p_k(\mathbf{r}) = \left( \frac{1}{2\pi\sigma_n^2} \right)^{\frac{N}{2}} \exp \left\{ - \sum_{i=1}^N \frac{(r_i - k)^2}{2\sigma_n^2} \right\} \quad k = 1, 2, 3, 4$$

- 选择似然函数最大的k对应的假设，等效于选择使下式最大的k

$$\left( \frac{2}{N} \sum_{i=1}^N r_i k \right) - k^2$$



- 这种情况下，贝叶斯准则转化为最大似然准则，各假设下的似然函数为

$$p_k(\mathbf{r}) = \left( \frac{1}{2\pi\sigma_n^2} \right)^{\frac{N}{2}} \exp \left\{ - \sum_{i=1}^N \frac{(r_i - k)^2}{2\sigma_n^2} \right\} \quad k = 1, 2, 3, 4$$

- 选择似然函数最大的k对应的假设，等效于选择使下式最大的k

$$\left( \frac{2}{N} \sum_{i=1}^N r_i k \right) - k^2$$


- 令  $\bar{m}$  代表样本均值，则上式在四种假设下分别为

$$2\bar{m} - 1 \quad 4\bar{m} - 4 \quad 6\bar{m} - 9 \quad 8\bar{m} - 16$$

- 易通过检验统计量  $\bar{m}$  进行假设判决



- 不难看出，检验统计量  $\bar{m}$  在四种假设下对应四种均值不同的高斯分布
- 其概率密度函数和判决区域如下图所示





## 8 复合假设检验

- 如果表征假设的参数是已知的, 则称这样的检验为**简单假设检验**
- 在实际中经常遇到表征假设的参数是未知的或随机的情况, 这时的检验称为**复合假设检验**

$$\begin{cases} H_1: r_i = \theta_1 + n_i, & i = 1, 2, \dots, m \\ H_0: r_i = \theta_0 + n_i, & i = 1, 2, \dots, m \end{cases}$$

- $\theta_i$  可能是未知常量或随机变量



# 贝叶斯方法

- $\theta$  为随机变量，且概率密度已知
- 已知假设  $H_0$  的先验概率  $\xi$ , 假设  $H_1$  的先验概率  $(1 - \xi)$
- 在两类假设下，似然函数用条件似然函数来表示

$$p_1(\mathbf{r}|\Theta)$$

$$p_0(\mathbf{r}|\Phi)$$

- 其中  $\Theta$  表示与  $H_1$  假设有关的随机参量，其概率密度函数为  $\omega_1(\Theta)$
- $\Phi$  表示与  $H_0$  假设有关的随机参量，其概率密度函数为  $\omega_0(\Phi)$

**考虑三分钟：针对该情况应当如何处理？**





- 此时的平均判决风险为

$$\begin{aligned}\bar{C} &= \xi C_{10} + (1 - \xi) C_{11} \\ &+ \int_{R_0} \left\{ (1 - \xi) (C_{01} - C_{11}) \int_{\Theta} p_1(\mathbf{r}|\Theta) \omega_1(\Theta) d\Theta - \xi (C_{10} - C_{00}) \int_{\Phi} p_0(\mathbf{r}|\Phi) \omega_0(\Phi) d\Phi \right\} d\mathbf{r}\end{aligned}$$



- 此时的平均判决风险为

$$\begin{aligned}\bar{C} &= \xi C_{10} + (1 - \xi) C_{11} \\ &+ \int_{R_0} \left\{ (1 - \xi) (C_{01} - C_{11}) \int_{\Theta} p_1(\mathbf{r}|\Theta) \omega_1(\Theta) d\Theta - \xi (C_{10} - C_{00}) \int_{\Phi} p_0(\mathbf{r}|\Phi) \omega_0(\Phi) d\Phi \right\} d\mathbf{r}\end{aligned}$$

- 合理地认为判错的代价大于判对得代价，则判决规则为

$$\frac{\int_{\Theta} p_1(\mathbf{r}|\Theta) \omega_1(\Theta) d\Theta}{\int_{\Phi} p_0(\mathbf{r}|\Phi) \omega_0(\Phi) d\Phi} \underset{H_0}{\overset{H_1}{\geq}} \frac{\xi (C_{10} - C_{00})}{(1 - \xi) (C_{01} - C_{11})} = \lambda_0$$

- 先验概率  $\xi$  未知时，类似简单假设检验，可利用极小极大准则判决



- 例
- 若观测信号为  $r$
- 噪声  $n$  为  $N(0, \sigma_n^2)$  高斯变量，噪声样本与信号统计独立
- 信号  $m$  为  $N(0, \sigma_m^2)$  高斯变量
- 多样本的二元假设检验

$$\begin{cases} H_1: r = m + n \\ H_0: r = n \end{cases}$$

- 给出似然比检验最佳检测器的形式



- 两种假设下观测信号的概率密度分布函数为

$$p_0(r) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2}{2\sigma_n^2} \right\}$$

$$p_1(r) = \int_{-\infty}^{\infty} p_1(r|m) p(m) dm$$



- 两种假设下观测信号的概率密度分布函数为

$$p_0(r) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2}{2\sigma_n^2} \right\}$$

$$p_1(r) = \int_{-\infty}^{\infty} p_1(r|m) p(m) dm$$

$$= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{(r-m)^2}{2\sigma_n^2} \right\} \frac{1}{\sqrt{2\pi} \sigma_m} \exp \left\{ -\frac{m^2}{2\sigma_m^2} \right\} dm$$



- 两种假设下观测信号的概率密度分布函数为

$$p_0(r) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2}{2\sigma_n^2} \right\}$$

$$p_1(r) = \int_{-\infty}^{\infty} p_1(r|m) p(m) dm$$

$$= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{(r-m)^2}{2\sigma_n^2} \right\} \frac{1}{\sqrt{2\pi} \sigma_m} \exp \left\{ -\frac{m^2}{2\sigma_m^2} \right\} dm$$

$$= \frac{1}{2\pi\sigma_n\sigma_m} \int_{-\infty}^{\infty} \exp \left\{ -\frac{\sigma_m^2 + \sigma_n^2}{2\sigma_n^2\sigma_m^2} \left( m^2 - \frac{2\sigma_m^2 r}{\sigma_m^2 + \sigma_n^2} m \right) - \frac{r^2}{2\sigma_n^2} \right\} dm$$



## • 两种假设下观测信号的概率密度分布函数为

$$p_0(r) = \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{r^2}{2\sigma_n^2}\right\}$$

$$p_1(r) = \int_{-\infty}^{\infty} p_1(r|m) p(m) dm$$

$$= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{(r-m)^2}{2\sigma_n^2}\right\} \frac{1}{\sqrt{2\pi}\sigma_m} \exp\left\{-\frac{m^2}{2\sigma_m^2}\right\} dm$$

$$= \frac{1}{2\pi\sigma_n\sigma_m} \int_{-\infty}^{\infty} \exp\left\{-\frac{\sigma_m^2 + \sigma_n^2}{2\sigma_n^2\sigma_m^2} \left(m^2 - \frac{2\sigma_m^2 r}{\sigma_m^2 + \sigma_n^2} m\right) - \frac{r^2}{2\sigma_n^2}\right\} dm$$

$$= \frac{1}{2\pi\sigma_n\sigma_m} \exp\left\{-\frac{r^2}{2(\sigma_m^2 + \sigma_n^2)}\right\} \int_{-\infty}^{\infty} \exp\left\{-\frac{\sigma_m^2 + \sigma_n^2}{2\sigma_n^2\sigma_m^2} \left(m - \frac{\sigma_m^2 r}{\sigma_m^2 + \sigma_n^2}\right)^2\right\} dm$$

$$= \frac{1}{\sqrt{2\pi}\sqrt{\sigma_m^2 + \sigma_n^2}} \exp\left\{-\frac{r^2}{2(\sigma_m^2 + \sigma_n^2)}\right\}$$



- 似然比为

$$\lambda(r) = \left( \frac{\sigma_n^2}{\sigma_n^2 + \sigma_m^2} \right)^{\frac{1}{2}} \exp \left\{ -\frac{r^2 \sigma_m^2}{2\sigma_n^2 (\sigma_n^2 + \sigma_m^2)} \right\} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$$

- 对数似然比为

$$r^2 \underset{H_0}{\overset{H_1}{\geq}} \frac{2\sigma_n^2 (\sigma_m^2 + \sigma_n^2)}{\sigma_m^2} \left[ \ln \lambda_0 + \frac{1}{2} \ln \left( 1 + \frac{\sigma_m^2}{\sigma_n^2} \right) \right] = V_T^2$$






- 似然比为

$$\lambda(r) = \left( \frac{\sigma_n^2}{\sigma_n^2 + \sigma_m^2} \right)^{\frac{1}{2}} \exp \left\{ - \frac{r^2 \sigma_m^2}{2 \sigma_n^2 (\sigma_n^2 + \sigma_m^2)} \right\} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$$

- 对数似然比为

$$r^2 \underset{H_0}{\overset{H_1}{\geq}} \frac{2 \sigma_n^2 (\sigma_m^2 + \sigma_n^2)}{\sigma_m^2} \left[ \ln \lambda_0 + \frac{1}{2} \ln \left( 1 + \frac{\sigma_m^2}{\sigma_n^2} \right) \right] = V_T^2$$





**复习:**

**理解和掌握几个基本概念与检测方法:**

多次测量下的检测及优点

多元假设检验

复合假设检验

**清楚知道每种检测准则的前提条件及其特点**

**逻辑结构、数学推广**



## 一致最大势检验

- 当  $\theta$  为未知参量时，这时可采用Neyman-Pearson准则,即约束虚警概率为常数，使检测概率最大。
- 一般说来，这样得到的检测器与未知参数  $\theta$  有关,检测器是无法实现的
- 如果这时得到的检测器的结构与未知参数无关，那么就可以实现最佳检验，称这样的检验为一致最大势检验



- 例
- 若观测信号为  $r$
- 噪声  $n$  为  $N(0, \sigma_n^2)$  高斯变量, 噪声样本与信号统计独立
- 信号  $m$  为未知的正数, 非随机
- 多样本的二元假设检验

$$\begin{cases} H_1: r = m + n \\ H_0: r = n \end{cases}$$

- 给出似然比检验最佳检测器的形式



- 两种假设下观测信号的概率密度分布函数为

$$p_1(r) = \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{(r-m)^2}{2\sigma_n^2}\right\} \quad p_0(r) = \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{r^2}{2\sigma_n^2}\right\}$$



- 两种假设下观测信号的概率密度分布函数为

$$p_1(r) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{(r - m)^2}{2\sigma_n^2} \right\} \quad p_0(r) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2}{2\sigma_n^2} \right\}$$

- $m$ 已知是正的, 对任意正的 $m$ 值, 似然比检验为

$$\lambda(r) = \frac{\frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2 - 2mr + m^2}{2\sigma_n^2} \right\}}{\frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2}{2\sigma_n^2} \right\}} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$$



- 两种假设下观测信号的概率密度分布函数为

$$p_1(r) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{(r - m)^2}{2\sigma_n^2} \right\} \quad p_0(r) = \frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2}{2\sigma_n^2} \right\}$$

- $m$ 已知是正的, 对任意正的 $m$ 值, 似然比检验为

$$\lambda(r) = \frac{\frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2 - 2mr + m^2}{2\sigma_n^2} \right\}}{\frac{1}{\sqrt{2\pi} \sigma_n} \exp \left\{ -\frac{r^2}{2\sigma_n^2} \right\}} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$$

- 取自然对数

$$r \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma_n^2}{m} \ln \lambda_0 + \frac{m}{2} = \gamma_1$$



- 注意到  $\gamma_1$  可以由虚警概率决定

$$P_F = \int_{\gamma_1}^{\infty} p_0(r) dr = \int_{\gamma_1}^{\infty} \frac{1}{\sqrt{2\pi} \sigma_n} \exp\left\{-\frac{r^2}{2\sigma_n^2}\right\} dr$$

- 一旦  $\gamma_1$  确定

$$\begin{matrix} H_1 \\ r \geq \gamma_1 \\ H_0 \end{matrix}$$

- 似然比检验不要求  $m$  的任何知识，一致最大势检验存在
- 一致最大势检验是指最佳检测器的结构与参数无关的检验





## 9 广义似然比检验

- 当  $\theta$  为未知参量时，一种方法是将估计得到的参数当作真实参数，应用到似然比检验当中。如果利用的估计是最大似然估计，此结果称为广义似然比检验


$$\lambda_g(\mathbf{r}) = \frac{\max_{\Theta} p_1(\mathbf{r}|\Theta)_{H_1}}{\max_{\Phi} p_0(\mathbf{r}|\Phi)_{H_0}} \geq \lambda_0$$



# 广义似然比检测合理性的讨论 (3分钟讨论)

给出一组观测值，判断它究竟属于哪种假设：

$$\lambda_g(\mathbf{r}) = \frac{\max_{\Theta} p_1(\mathbf{r}|\Theta)_{H_1}}{\max_{\Phi} p_0(\mathbf{r}|\Phi)_{H_0}} \geq \lambda_0$$





- 例
- 若接收信号的 $K$ 次独立观测为  $r_1, r_2, \dots, r_k$
- 每个噪声样本  $n_i, i = 1, 2, \dots, K$  都是独立同分布的  $N(0, \sigma_n^2)$  高斯变量，噪声样本与信号样本统计独立
- 多样本的二元假设检验
$$\begin{cases} H_1: r_i = m + n_i, & i = 1, 2, \dots, K \\ H_0: r_i = n_i & , i = 1, 2, \dots, K \end{cases}$$
- 信号 $m$ 为未知的正数
- 求广义似然比检验



- 两种假设下观测信号的概率密度分布函数为

$$p_1(\mathbf{r}|m) = \prod_{i=1}^K p_1(r_i) = \left( \frac{1}{2\pi\sigma_n^2} \right)^{\frac{K}{2}} \exp \left\{ - \sum_{i=1}^K \frac{(r_i - m)^2}{2\sigma_n^2} \right\}$$

$$p_0(\mathbf{r}) = \prod_{i=1}^K p_0(r_i) = \left( \frac{1}{2\pi\sigma_n^2} \right)^{\frac{K}{2}} \exp \left\{ - \sum_{i=1}^K \frac{r_i^2}{2\sigma_n^2} \right\}$$



- 两种假设下观测信号的概率密度分布函数为

$$p_1(\mathbf{r}|m) = \prod_{i=1}^K p_1(r_i) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{\frac{K}{2}} \exp\left\{-\sum_{i=1}^K \frac{(r_i - m)^2}{2\sigma_n^2}\right\}$$
$$p_0(\mathbf{r}) = \prod_{i=1}^K p_0(r_i) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{\frac{K}{2}} \exp\left\{-\sum_{i=1}^K \frac{r_i^2}{2\sigma_n^2}\right\}$$

- $m$  已知是正的, 利用最大似然估计对  $m$  进行估计

$$\frac{\partial \ln p_1(\mathbf{r}|m)}{\partial m} = 0$$



- 两种假设下观测信号的概率密度分布函数为

$$p_1(\mathbf{r}|m) = \prod_{i=1}^K p_1(r_i) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{\frac{K}{2}} \exp\left\{-\sum_{i=1}^K \frac{(r_i - m)^2}{2\sigma_n^2}\right\}$$
$$p_0(\mathbf{r}) = \prod_{i=1}^K p_0(r_i) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{\frac{K}{2}} \exp\left\{-\sum_{i=1}^K \frac{r_i^2}{2\sigma_n^2}\right\}$$

- $m$  已知是正的，利用最大似然估计对  $m$  进行估计

$$\frac{\partial \ln p_1(\mathbf{r}|m)}{\partial m} = 0$$

- 可以得到  $m$  的估计值

$$\hat{m} = \frac{1}{K} \sum_{i=1}^K r_i$$



- 广义似然比检验为

$$\lambda_g(\mathbf{r}) = \frac{\prod_{i=1}^K \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{(r_i - \hat{m})^2}{2\sigma_n^2}\right\}}{\prod_{i=1}^K \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{r_i^2}{2\sigma_n^2}\right\}} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$$



- 广义似然比检验为

$$\lambda_g(\mathbf{r}) = \frac{\prod_{i=1}^K \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{(r_i - \hat{m})^2}{2\sigma_n^2}\right\}}{\prod_{i=1}^K \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{r_i^2}{2\sigma_n^2}\right\}} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$$

- 取自然对数

$$\frac{1}{2\sigma_n^2 K} \left( \sum_{i=1}^K r_i \right)^2 \underset{H_0}{\overset{H_1}{\geq}} \ln \lambda_0$$

- 如果  $\lambda_0$  小于或等于1，则判决总是  $H_1$
- 因此总是选择  $\lambda_0$  大于1，等效的检验为

$$\left( \frac{1}{\sqrt{K}} \sum_{i=1}^K r_i \right)^2 \underset{H_0}{\overset{H_1}{\geq}} 2\sigma_n^2 \ln \lambda_0 = \gamma_1^2$$





- 广义似然比检验为

$$\lambda_g(\mathbf{r}) = \frac{\prod_{i=1}^K \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{(r_i - \hat{m})^2}{2\sigma_n^2}\right\}}{\prod_{i=1}^K \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left\{-\frac{r_i^2}{2\sigma_n^2}\right\}} \underset{H_0}{\overset{H_1}{\geq}} \lambda_0$$

- 取自然对数

$$\frac{1}{2\sigma_n^2 K} \left( \sum_{i=1}^K r_i \right)^2 \underset{H_0}{\overset{H_1}{\geq}} \ln \lambda_0$$

- 如果  $\lambda_0$  小于或等于1，则判决总是  $H_1$
- 因此总是选择  $\lambda_0$  大于1，等效的检验为


$$\left( \frac{1}{\sqrt{K}} \sum_{i=1}^K r_i \right)^2 \underset{H_0}{\overset{H_1}{\geq}} 2\sigma_n^2 \ln \lambda_0 = \gamma_1^2$$



- 进一步等效为

$$\left| \frac{1}{\sqrt{K}} \sum_{k=1}^K r_k \right| \underset{H_0}{\overset{H_1}{\geq}} \gamma_1$$

- 广义似然比的判决区为





## 10 序贯检测

考察过去学过的检测方法：

$$\frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\xi(C_{10} - C_{00})}{(1 - \xi)(C_{01} - C_{11})}$$

$$\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0$$



## 10 序贯检测

考察过去学过的检测方法：

$$\frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\xi(C_{10} - C_{00})}{(1 - \xi)(C_{01} - C_{11})}$$

$$\lambda(r) = \frac{p_1(r)}{p_0(r)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda_0$$

- 当似然比与阈值相等时，或者左右两端非常非常接近时，该如何处理？
- 这时就用由瓦尔德提出的序贯检测。





## 10 序贯检测

- 在许多实际情况中，观测可以按一个顺序的方式进行。每次观测之后执行一次测试，作三个可能的判决之一。
- (1) 判决  $H_1$
- (2) 判决  $H_0$
- (3) 没有足够的信息支持判决  $H_1$  或  $H_0$
- 如果判决 (1) 或 (2) 作出，假设检验过程停止，否则，再进行附加的观测，再进行一次测试。这个过程一直持续到做出 (1) 或 (2) 的判决



- 假设  $r_k, k=1, 2, \dots, K$  表示矢量  $\mathbf{r}_K$  的第  $k$  次观测的采样
- 基于第一次到第  $K$  次观测的似然比

$$\lambda(\mathbf{r}_K) = \frac{p_1(\mathbf{r}_K)}{p_0(\mathbf{r}_K)}$$

- 假设每次观测有相同的分布且相互独立，则似然比

$$\lambda(\mathbf{r}_K) = \frac{p_1(\mathbf{r}_K)}{p_0(\mathbf{r}_K)} = \prod_{k=1}^K \frac{p_1(r_k)}{p_0(r_k)}$$

- 我们将根据虚警概率  $P_F = \alpha$  和漏检概率  $P_M = \beta$  决定判决门限  $\lambda_0$  和  $\lambda_1$ ，并进行如下检验

$$\lambda(\mathbf{r}_K) \geq \lambda_1, \text{ 判决为 } H_1$$

$$\lambda(\mathbf{r}_K) \leq \lambda_0, \text{ 判决为 } H_0$$

$$\lambda_0 < \lambda(\mathbf{r}_K) < \lambda_1, \text{ 进行附加观测}$$



- 假设  $r_k, k=1, 2, \dots, K$  表示矢量  $\mathbf{r}_K$  的第  $k$  次观测的采样
- 基于第一次到第  $K$  次观测的似然比

$$\lambda(\mathbf{r}_K) = \frac{p_1(\mathbf{r}_K)}{p_0(\mathbf{r}_K)}$$

- 假设每次观测有相同的分布且相互独立，则似然比

$$\lambda(\mathbf{r}_K) = \frac{p_1(\mathbf{r}_K)}{p_0(\mathbf{r}_K)} = \prod_{k=1}^K \frac{p_1(r_k)}{p_0(r_k)}$$

- 我们将根据虚警概率  $P_F = \alpha$  和漏检概率  $P_M = \beta$  决定判决门限  $\lambda_0$  和  $\lambda_1$ ，并进行如下检验

$$\lambda(\mathbf{r}_K) \geq \lambda_1, \text{ 判决为 } H_1$$

$$\lambda(\mathbf{r}_K) \leq \lambda_0, \text{ 判决为 } H_0$$

- **核心：双阈值**

$$\lambda_0 < \lambda(\mathbf{r}_K) < \lambda_1, \text{ 进行附加观测}$$



- 检测概率

$$P_D = \int_{R_1} p_1(\mathbf{r}_K) d\mathbf{r}_K = \int_{R_1} \lambda(\mathbf{r}_K) p_0(\mathbf{r}_K) d\mathbf{r}_K$$

- 由于

$$\lambda(\mathbf{r}_K) \geq \lambda_1$$





- 检测概率

$$P_D = \int_{R_1} p_1(\mathbf{r}_K) d\mathbf{r}_K = \int_{R_1} \lambda(\mathbf{r}_K) p_0(\mathbf{r}_K) d\mathbf{r}_K$$

- 由于

$$\lambda(\mathbf{r}_K) \geq \lambda_1$$

- 因此

$$1 - P_M = P_D \geq \lambda_1 \int_{R_1} p_0(\mathbf{r}_K) d\mathbf{r}_K = \lambda_1 P_F$$

$$\lambda_1 \leq \frac{1 - P_M}{P_F} = \frac{1 - \beta}{\alpha}$$



- 检测概率

$$P_D = \int_{R_1} p_1(\mathbf{r}_K) d\mathbf{r}_K = \int_{R_1} \lambda(\mathbf{r}_K) p_0(\mathbf{r}_K) d\mathbf{r}_K$$

- 由于

$$\lambda(\mathbf{r}_K) \geq \lambda_1$$

- 因此

$$1 - P_M = P_D \geq \lambda_1 \int_{R_1} p_0(\mathbf{r}_K) d\mathbf{r}_K = \lambda_1 P_F$$

$$\lambda_1 \leq \frac{1 - P_M}{P_F} = \frac{1 - \beta}{\alpha}$$

- 同理

$$\lambda_0 \geq \frac{P_M}{1 - P_F} = \frac{\beta}{1 - \alpha}$$



- 值得研究的问题
  - 1.这个过程不终止的概率是多少
  - 2.随机变量 $K$ 的一些分布特性是什么
  - 3.实际上，采样数 $K$ 的期望值是多少



- 取自然对数得到

$$\ln \lambda_0 < \ln \frac{p_1(r_1)}{p_0(r_1)} + \dots + \ln \frac{p_1(r_{K-1})}{p_0(r_{K-1})} < \ln \lambda_1$$

- 令 
$$L(r_k) = \ln \frac{p_1(r_k)}{p_0(r_k)}$$

- 则 
$$\ln \lambda_0 < L(r_1) + \dots L(r_{K-1}) < \ln \lambda_1$$



- 取自然对数得到

$$\ln \lambda_0 < \ln \frac{p_1(r_1)}{p_0(r_1)} + \dots + \ln \frac{p_1(r_{K-1})}{p_0(r_{K-1})} < \ln \lambda_1$$

- 令  $L(r_k) = \ln \frac{p_1(r_k)}{p_0(r_k)}$

- 则  $\ln \lambda_0 < L(r_1) + \dots L(r_{K-1}) < \ln \lambda_1$

- 和式写成递归关系式  $L(\mathbf{r}_K) = L(\mathbf{r}_{K-1}) + L(r_K)$

- 其中  $L(\mathbf{r}_{K-1}) = \sum_{k=1}^{K-1} L(r_k)$



- $L(\mathbf{r}_K)$  在两种假设下的期望值为

$$E[L(\mathbf{r}_K) | H_1] = \beta \ln \lambda_0 + (1 - \beta) \ln \lambda_1$$

$$E[L(\mathbf{r}_K) | H_0] = \alpha \ln \lambda_1 + (1 - \alpha) \ln \lambda_0$$



- $L(\mathbf{r}_K)$  在两种假设下的期望值为

$$E[L(\mathbf{r}_K) | H_1] = \beta \ln \lambda_0 + (1 - \beta) \ln \lambda_1$$

$$E[L(\mathbf{r}_K) | H_0] = \alpha \ln \lambda_1 + (1 - \alpha) \ln \lambda_0$$

- $B$  是取0和1的随机变量，满足

$$B_K = \begin{cases} 1, & \text{高达 } (K-1) \text{ 次采样没有作出判决} \\ 0, & \text{在较早的采样时作出判决} \end{cases}$$

- 则

$$L(\mathbf{r}_K) = \sum_{k=1}^K L(r_k) = \sum_{k=1}^{\infty} B_k L(r_k)$$



$$E[L(\mathbf{r}_K) | H_1] = E[L(r) | H_1] \cdot \sum_{k=1}^{\infty} E[B_k | H_1]$$
$$E[L(\mathbf{r}_K) | H_0] = E[L(r) | H_0] \cdot \sum_{k=1}^{\infty} E[B_k | H_0]$$

• 其中

$$E[L(r) | H_1] = E[L(r_1) | H_1] = \dots = E[L(r_K) | H_1]$$
$$E[L(r) | H_0] = E[L(r_1) | H_0] = \dots = E[L(r_K) | H_0]$$





$$E[L(\mathbf{r}_K) | H_1] = E[L(r) | H_1] \cdot \sum_{k=1}^{\infty} E[B_k | H_1]$$
$$E[L(\mathbf{r}_K) | H_0] = E[L(r) | H_0] \cdot \sum_{k=1}^{\infty} E[B_k | H_0]$$

• 其中  $E[L(r) | H_1] = E[L(r_1) | H_1] = \dots = E[L(r_K) | H_1]$

$$E[L(r) | H_0] = E[L(r_1) | H_0] = \dots = E[L(r_K) | H_0]$$

• 并且

$$\sum_{k=1}^{\infty} E[B_k | H_1] = E[K | H_1]$$

$$\sum_{k=1}^{\infty} E[B_k | H_0] = E[K | H_0]$$



- 则

$$E[L(r) | H_1] \cdot E[K | H_1] = \beta \ln \lambda_0 + (1 - \beta) \ln \lambda_1$$

$$E[K | H_1] = \frac{\beta \ln \lambda_0 + (1 - \beta) \ln \lambda_1}{E[L(r | H_1)]}$$

- 同理

$$E[K | H_0] = \frac{\alpha \ln \lambda_1 + (1 - \alpha) \ln \lambda_0}{E[L(r | H_0)]}$$



- 例 若接收信号的**K**次独立观测为  $r_1, r_2, \dots, r_k$
- 每个噪声样本  $n_i, i = 1, 2, \dots, K$  都是独立同分布的  $N(0, \sigma_n^2)$  高斯变量，噪声样本与信号样本统计独立
- 多样本的二元假设检验
$$\begin{cases} H_1: r_i = m + n_i, & i = 1, 2, \dots, K \\ H_0: r_i = n_i & , i = 1, 2, \dots, K \end{cases}$$
- 令  $\sigma_n^2 = 1, m = 1$
- 确定判决规则，以使  $P_F = \alpha = 0.1 \quad P_M = \beta = 0.1$
- 确定每个假设下**K**的期望值



- 似然比为

$$\begin{aligned}\lambda(\mathbf{r}_K) &= \exp \left\{ \sum_{k=1}^K \frac{r_k^2}{2\sigma_n^2} - \sum_{k=1}^K \frac{(r_k - m)^2}{2\sigma_n^2} \right\} \\ &= \exp \left\{ \sum_{k=1}^K r_k - \frac{K}{2} \right\}\end{aligned}$$



- 似然比为

$$\begin{aligned}\lambda(\mathbf{r}_K) &= \exp \left\{ \sum_{k=1}^K \frac{r_k^2}{2\sigma_n^2} - \sum_{k=1}^K \frac{(r_k - m)^2}{2\sigma_n^2} \right\} \\ &= \exp \left\{ \sum_{k=1}^K r_k - \frac{K}{2} \right\}\end{aligned}$$

- 取自然对数

$$L(\mathbf{r}_K) = \ln \lambda(\mathbf{r}_K) = \sum_{k=1}^K r_k - \frac{K}{2}$$

$$\lambda_1 \leq \frac{1 - P_M}{P_F} = \frac{1 - \beta}{\alpha} = 9 \quad \ln \lambda_1 = 2.197$$

$$\lambda_0 \geq \frac{P_M}{1 - P_F} = \frac{\beta}{1 - \alpha} = \frac{1}{9} \quad \ln \lambda_0 = -2.197$$



- 判决规则为

$$L(\mathbf{r}_K) \geq 2.197, \text{ 判决为 } H_1$$

$$L(\mathbf{r}_K) \leq -2.197, \text{ 判决为 } H_0$$

$$-2.197 < L(\mathbf{r}_K) < 2.197, \text{ 进行附加观测}$$



- 判决规则为

$$L(\mathbf{r}_K) \geq 2.197, \text{ 判决为 } H_1$$

$$L(\mathbf{r}_K) \leq -2.197, \text{ 判决为 } H_0$$

$$-2.197 < L(\mathbf{r}_K) < 2.197, \text{ 进行附加观测}$$

- 在两种假设下 $\mathbf{K}$ 的期望值为

$$E[K|H_1] = \frac{\beta \ln \lambda_0 + (1 - \beta) \ln \lambda_1}{E[L(r|H_1)]} = \frac{0.9 \times 2.197 - 0.1 \times 2.197}{0.5} = 3.5152$$

$$E[K|H_0] = \frac{\alpha \ln \lambda_1 + (1 - \alpha) \ln \lambda_0}{E[L(r|H_0)]} = \frac{0.1 \times 2.197 - 0.9 \times 2.197}{-0.5} = 3.5152$$



**复习:**

**理解和掌握几个基本概念与检测方法:**

多次测量下的检测及优点

多元假设检验

复合假设检验

广义似然比检测

序贯检测

**清楚知道每种检测准则的前提条件及其特点**

**逻辑结构、数学推广**





**谢谢大家!**